

Predicción de géneros musicales

Alexis Hernández Morales

Facultad de Ciencias Físico Matemáticas, Universidad Autónoma de Nuevo León, San
Nicolás de los Garza, México.

1. Introducción

La música, en su diversidad y complejidad, ha sido naturalmente un objeto de estudio. Actualmente las plataformas como *Spotify* ofrecen acceso a una enorme biblioteca de canciones, además de generar una cantidad masiva de datos sobre las características acústicas y las preferencias de los usuarios. Estos datos dan lugar a una oportunidad única para aplicar técnicas de *Big Data* con el objetivo de mejorar la categorización y predicción de géneros musicales, una tarea de gran interés para personalizar las recomendaciones y enriquecer la experiencia del usuario.

2. Antecedentes

Para este proyecto se utilizaron como soporte las siguientes investigaciones previas:

Los investigadores Chaudhary et al., utilizando herramientas de *Big Data* para analizar la correlación y la distancia unitaria entre variables propias de la música [1].

Siddharth, realiza un sistema de recomendación de canciones utilizando la API de *Spotify* con *Pyspark* mediante el uso de herramientas de aprendizaje automático para el manejo de las variables características de las pistas[2].

3. Descripción de los datos

Los datos utilizados fueron extraídos originalmente mediante el uso del API de Spotify. Cuando se extraen datos de la API de *Spotify*, la información puede incluir una variedad de detalles sobre diferentes elementos, como canciones, artistas, álbumes y listas de reproducción. La API de *Spotify* proporciona acceso a muchos recursos de música y múltiples campos de información.

Esta base de datos se descargó de *Kaggle* con 30 000 registros y 23 columnas con especificaciones de cada canción, clasificadas en seis categorías, siendo estas EDM, Latino, Pop, R&B, Rap y Rock. Estas categorías son determinadas por *Spotify* junto con especificaciones numéricas respecto al audio de las canciones y como estas se comportan como lo son `danceability`, `energy`, `key`, `loudness`, `mode`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `tempo`, `duration ms` y `track popularity`.

4. Herramientas

Como herramienta principal para el análisis de este proyecto se utilizó **PySpark** debido a la capacidad de manejar y procesar grandes volúmenes de datos, que si bien la escala de datos a utilizar no cuenta con un gran tamaño, en un futuro es posible poner a prueba una base con una mayor cantidad de registros de la API de *Spotify* y realizar un estudio igual o similar donde ahora sea una necesidad el uso de esa herramienta.

5. Estudio estadístico

A continuación se muestran histogramas de las distribuciones de las variables numéricas que caracterizan las canciones.

6. Metodología

6.1. Selector de Umbral de Varianza

El Selector de Umbral de Varianza es un algoritmo utilizado en la selección de características para modelos de aprendizaje automático. Su objetivo es eliminar las variables que tienen una baja varianza, ya que se considera que aportan poca o ninguna información al modelo.

Se calcula la varianza de cada característica en el conjunto de datos, se define un valor mínimo de varianza por el cual las variables serán descartadas y las que tienen una varianza superior al umbral se mantienen, mientras que aquellas con varianza inferior al umbral se descartan, ya que no aportan suficiente variabilidad para diferenciar las muestras de manera significativa.

6.2. Bosque Aleatorio

El Bosque Aleatorio es un método de aprendizaje automático que utiliza Árboles de Decisión para crear predicciones y clasificaciones. Cuando el Bosque Aleatorio esta prediciendo un nuevo ítem basado en ciertos atributos, cada Árbol de Decisión da su propia clasificación como resultado, entonces el resultado general del Bosque Aleatorio será el mayor numero de taxonomía. En el caso de una regresión el resultado sera el valor promedio de todos los Arboles de Decisión.

6.3. Árbol de Decisión

El Árbol de Decisión es un proceso que permiten la construcción de modelos de predicción basándose en su clasificación según ciertas características o propiedades, o en la regresión mediante la relación entre distintas variables para predecir el valor de otra. Esta estructurado por ramas y nodos, los nodos internos representan cada una de las características o propiedades a considerar para tomar una decisión, las ramas representan la decisión en función de una determinada condición y los nodos finales representan el resultado de la decisión.

7. Métricas de desempeño

A partir de los valores obtenidos de los modelos se utilizan métricas para medir el desempeño con el que el modelo esta realizando estas predicciones y así saber lo bien o mal que se esta evaluando.




Figura 1: Distribuciones de las variables *danceability*, *energy*, *key*, *loudness*, *mode*, *speechiness*, *acousticness*, *instrumentalness*, *liveness*, *valence*, *tempo*, *duration ms* y *track popularity*.

- Exactitud: Es la proporción de verdaderos positivos y verdaderos negativos con respecto a todas las observaciones positivas y negativas.
- Puntuación $F1$: La puntuación $F1$ es la media armónica de la precisión y la puntuación de recuperación. Da el mismo peso tanto a la precisión como a la recuperación para medir su rendimiento en términos de precisión.

8. Métricas de error

Se utilizó el Error Absoluto Medio y el Error de Raíz Cuadrada Media para medir la efectividad del modelo.

8.1. Error Absoluto Medio

El Error Absoluto Medio es un indicador de desempeño que mide el tamaño de error absoluto

$$\text{EAM} = \frac{\sum_i |Y - \hat{Y}|}{Y}. \quad (1)$$

8.2. Error de Raíz Cuadrada Media

El Error de Raíz Cuadrada Media es la desviación estándar de los valores residuales. Los valores residuales son una medida de la distancia de los puntos de datos de una regresión. El Error de Raíz Cuadrada Media mide cuál es el nivel de dispersión de estos valores residuales

$$\text{ERCM} = \sqrt{\frac{\sum_i (Y - \hat{Y})^2}{N}}. \quad (2)$$

9. Resultados

Se utilizaron diferentes métodos para obtener la predicción de los datos del género musical indexado, los cuales se muestran a continuación.

9.1. Bosque Aleatorio

Utilizando las clasificaciones indexadas y el método de Bosque Aleatorio para la predicción del genero musical se obtuvo una exactitud del 45 %, con un Error Absoluto Medio de 1,19 y un Error de Raíz Cuadrada de 1,84.

9.2. Árbol de Decisión

Al procesar los datos mediante el método de Árbol de Decisión enfocado a la predicción del genero musical indexado se obtuvo una exactitud del 47 %, con un Error Absoluto Medio de 1,21 y un Error de Raíz Cuadrada de 1,87.

10. Conclusiones

Con los resultados obtenidos se puede apreciar que tanto el método de Bosque Aleatorio como de Árbol de Decisión tuvieron desempeños bajos con predicciones que difieren considerablemente de los datos reales, mostrando dificultades para representar estos datos.

Con el análisis realizado se hace ver la necesidad de un cambio en las técnicas de predicción así como del procesamiento de los datos para así encontrar información de valor y que pueda ser utilizada como resultado del estudio.

Referencias

- [1] S. Chaudhary, V. Karthik, R. Shankar, A. Taranum, and E. Naresh. Parametrized optimization based on an investigation of musical similarities using spark and hadoop. *SN Computer Science*, 5(1), Dec. 2023. ISSN 2661-8907. doi: 10.1007/s42979-023-02367-y.
- [2] Siddharth. Spotify recommendation system using pyspark and kafka streaming. *Analytics Vidhya*, 2021.